UNIFACISA

CENTRO UNIVERSITÁRIO

Programar em linguagem estruturada para ciências de dados básicos

Prof. Matheus Batista

UNIFACISA
CENTRO UNIVERSITÁRIO

Processo avaliativo

Modelo Avaliativo

O estudante será **APROVADO** se:

Frequência ≧ a 75% e Nota Final ≧ a 7,0

O estudante **NÃO TEM DIREITO A FAZER A AVALIAÇÃO FINAL** se:

Nota do Projeto < 4,0

O estudante fará **AVALIAÇÃO FINAL** se:

Frequência ≧ a 75%, Nota do Projeto ≧ 4,0 e "Nota do Projeto+Avaliação Individual" < 7

O estudante será **APROVADO** se:

A Avaliação Final + Nota do Projeto ≧ 6,0

UNIFACISA
CENTRO UNIVERSITÁRIO

Processo avaliativo

Entregável	Data	Conteúdo	Pontos avaliados
Entrega Fase 1	14/03	• Código fonte num arquivo .ipynb • Relatório parcial em PDF • Implementar scripts para leitura, limpeza e análise estatística básica de um dataset real	• Organização do código • Código executar sem erros • Documentação do código • Aplicação correta dos métodos aprendidos durante as aulas • Relatório parcial com as análises iniciais do dataset
Avaliação individual	06/04	Prova teórica com 5 questões	Questões respondidas
Entrega Fase 2	13/04	• Código fonte num arquivo .ipynb • Relatório parcial em PDF	• Organização do código • Código executar sem erros • Documentação do código • Aplicação correta dos métodos aprendidos durante as aulas • Relatório final com as análises do dataset
Prova Final	20/04	Prova teórica com 5 questões	Questões respondidas

UNIFACISA
CENTRO UNIVERSITÁRIO

Cronograma de disciplinas e assunto

Semana	Aula	Tema
1	1 – 09/02	• Apresentação da disciplina • O que é Data Science? • Ciclo de análise de dados • Aplicações no mundo real • Apresentação do projeto da disciplina • Divisão das equipes • Explicar os pontos que serão avaliados • Introdução a ferramentas de análise de dados
2	2 – 23/02	• Condicionais (if/else) • Laços de repetição (for/while) • Funções • Modularização de código • Lista, tuplas e dicionários • Manipulação de arquivos CSV

UNIFACISA
CENTRO UNIVERSITÁRIO

Cronograma de disciplinas e assunto

Semana	Aula	Tema
3	3 – 09/03	• Introdução ao NumPy, Pandas • Operações com biblioteca Pandas • Onde encontrar datasets públicos? • Operações simples com datasets • Pré-visualização de dados • Tratamentos de dados • Organização dos dados • Agrupamentos e agregações
	4 – 14/03	• Entrega da fase 1 do projeto
4	6 – 23/03	• Visualização de dados • Visualização gráfica • Correlações espúrias

UNIFACISA
CENTRO UNIVERSITÁRIO

Cronograma de disciplinas e assunto

Semana	Aula	Tema
5	5 – 06/04	• Avaliação individual • Acompanhamento dos projetos
6	6 – 20/04	• Avaliação final

UNIFACISA
CENTRO UNIVERSITÁRIO

O que é Data Science?

Data Science, ou Ciência de Dados, é uma área interdisciplinar que combina **matemática, estatística**, **programação** e **inteligência artificial** para **extrair informações valiosas a partir de dados!**

UNIFACISA
CENTRO UNIVERSITÁRIO

Com qual objetivo? Para que?

A área busca extrair insights e conhecimento de dados para resolver problemas, identificar oportunidades e otimizar processos

UNIFACISA
CENTRO UNIVERSITÁRIO

Quais as subáreas da Ciência de Dados?

- Matemática e Estatística
- Engenharia de dados (Data Engineering)
- Análise de dados (Data analysis)
- Machine Learning
- Deep Learning
- NLP (Processamento natural de linguagem)
- Business Intelligence (BI)
- Experimentação e testes A/B
- Data Governance e Ética em IA

Quais as subáreas da Ciência de Dados?

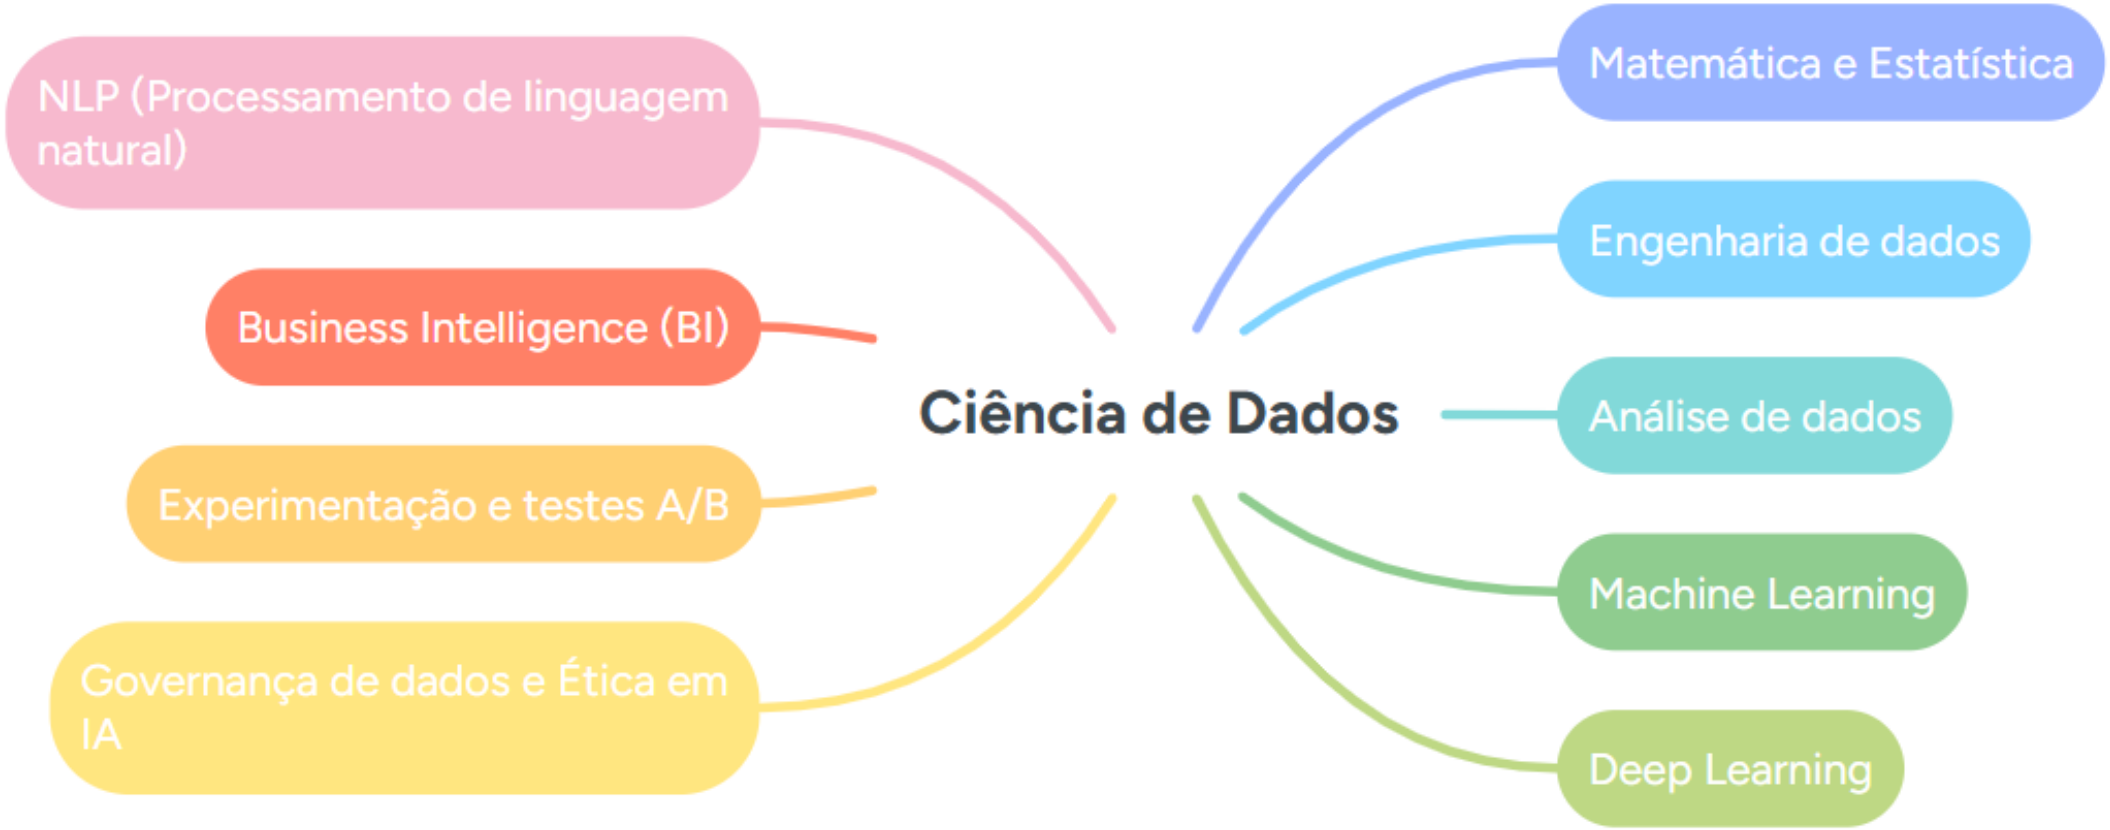

UNIFACISA
CENTRO UNIVERSITÁRIO

Matemática e estatística

Base matemática da Data Science

- Testes estatísticos
- Modelos probabilísticos
- Inferência e análise de hipóteses
- Distribuições (normal, binomial, etc)
- Normalizações

Engenharia de dados

Foca na coleta, armazenamento e preparação dos dados

- ETL (extract, transform, load)
- Pipeline de dados
- Banco de dados (SQL/NoSQL)
- BigData (Hadoop, Spark, Elasticsearch, Snowflake, Redshift)

Análise de dados

Busca explorar e interpretar os dados

- Estatística descritiva
- Visualizações (dashboard, gráficos)
- Análises exploratórias (EDA)
- Ferramentas: excel, Power BI, Tableau, **Python** (Pandas, Seaborn)

Machine Learning

Criação de modelos preditivos ou classificadores

- Modelos supervisionados e não supervisionados
- Redes neurais, árvores de decisão, KNN, SVM
- Ferramentas: Scitik-learn, TensorFlow, PyTorch

Deep Learning

Subcampo de machine learning que usa redes neurais profundas

- Processamento de imagens (visão computacional)
- Processamento de linguagem natural (NLP)
- LLM (Large Language Models: GPT, BERN, CNN, RNN, Transformers)

NLP – Processamento de Linguagem Natural

Análise de Textos e linguagem humana

- Classificação de sentimentos
- Geração de texto
- Tradução automática
- Chatbot
- Ferramentas: NLTK, spaCY, HuggingFace, Google DocAI, MS DocIntelligence, AWS Textract

Business Intelligence (BI)

Foco em decisões estratégicas com dashboards e relatórios

- KPI, indicadores, metas
- Storytelling com dados
- Ferramentas: Power BI, Tableau, Qlik Sense

Experimentação e testes A/B

Usada para validar hipóteses com experimentos controlados

- Testes A/B, multivariados
- Métricas de impacto
- Design experimental

UNIFACISA
CENTRO UNIVERSITÁRIO

Data Governance e Ética em IA

- Privacidade de dados (LGPD, GDPR)
- Viés em modelos
- Explicabilidade e transparência
- Conformidade (Compliance)
- Retenção dos dados

Ciclo de análise de dados

UNIFACISA
CENTRO UNIVERSITÁRIO

Ciclo de análise de dados na prática

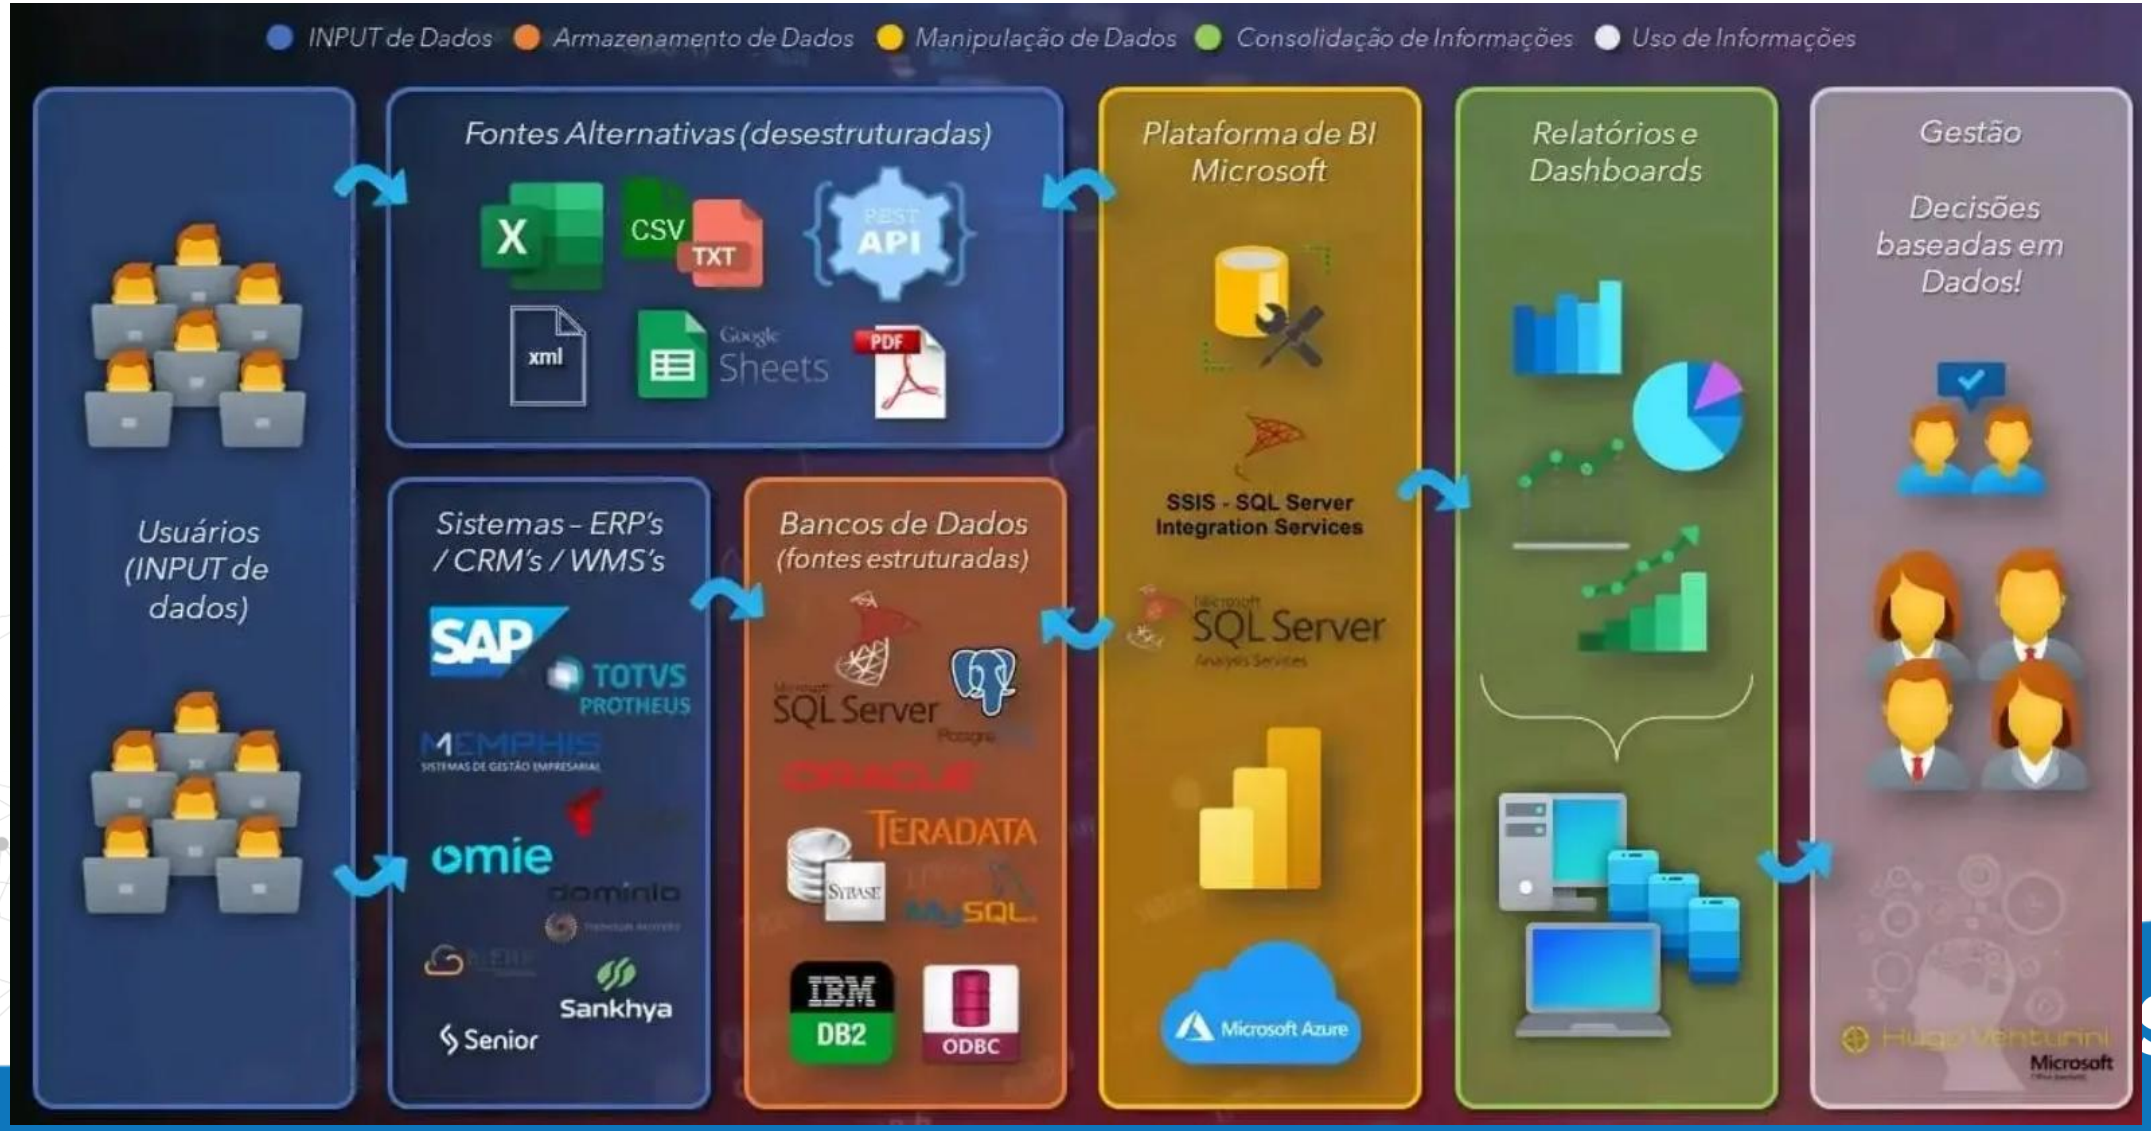

Quais linguagens mais usadas?

- Python: comunidade gigante, ecossistema de libs como Pandas, NumPY, SciPY, MatPlotLib, Seaborn e TensorFlow
- R: Muito usado na academia, muitoss pacotes para manipulação como ggplot2, dplyr, caret, shiny
- SQL: Não é linguagem de programação, mas é muito usada para manipular, exportar e armazenar dados
- Java: Muito usada em aplicações de produção em grande escala que usam Apache Hadoop e Apache Spark
- Julia: Linguagem multiparadigma, projetada para computação numérica de alto desempenho

Principais lugares para pegar datasets públicos?

- Kaggle: https://www.kaggle.com/datasets
- HuggingFace: https://huggingface.co/datasets
- Dados públicos do Brasil: https://dados.gov.br/home
- Dados de censo: https://www.ibge.gov.br
- Portal da transparência: https://portaldatransparencia.gov.br/download-de-dados
- Papers with Code: https://paperswithcode.com/datasets
- Dados públicos dos EUA: https://data.gov
- Google Dataset Search: https://datasetsearch.research.google.com
- Github: https://github.com/awesomedata/awesome-public-datasets

Como baixar datasets?

- Na maioria dos sites, são disponibilizados arquivos CSV para download
- Alguns sites disponibilizam import do dataset sem a necessidade de realizar o download, como o Kaggle

Como baixar datasets no Kaggle?

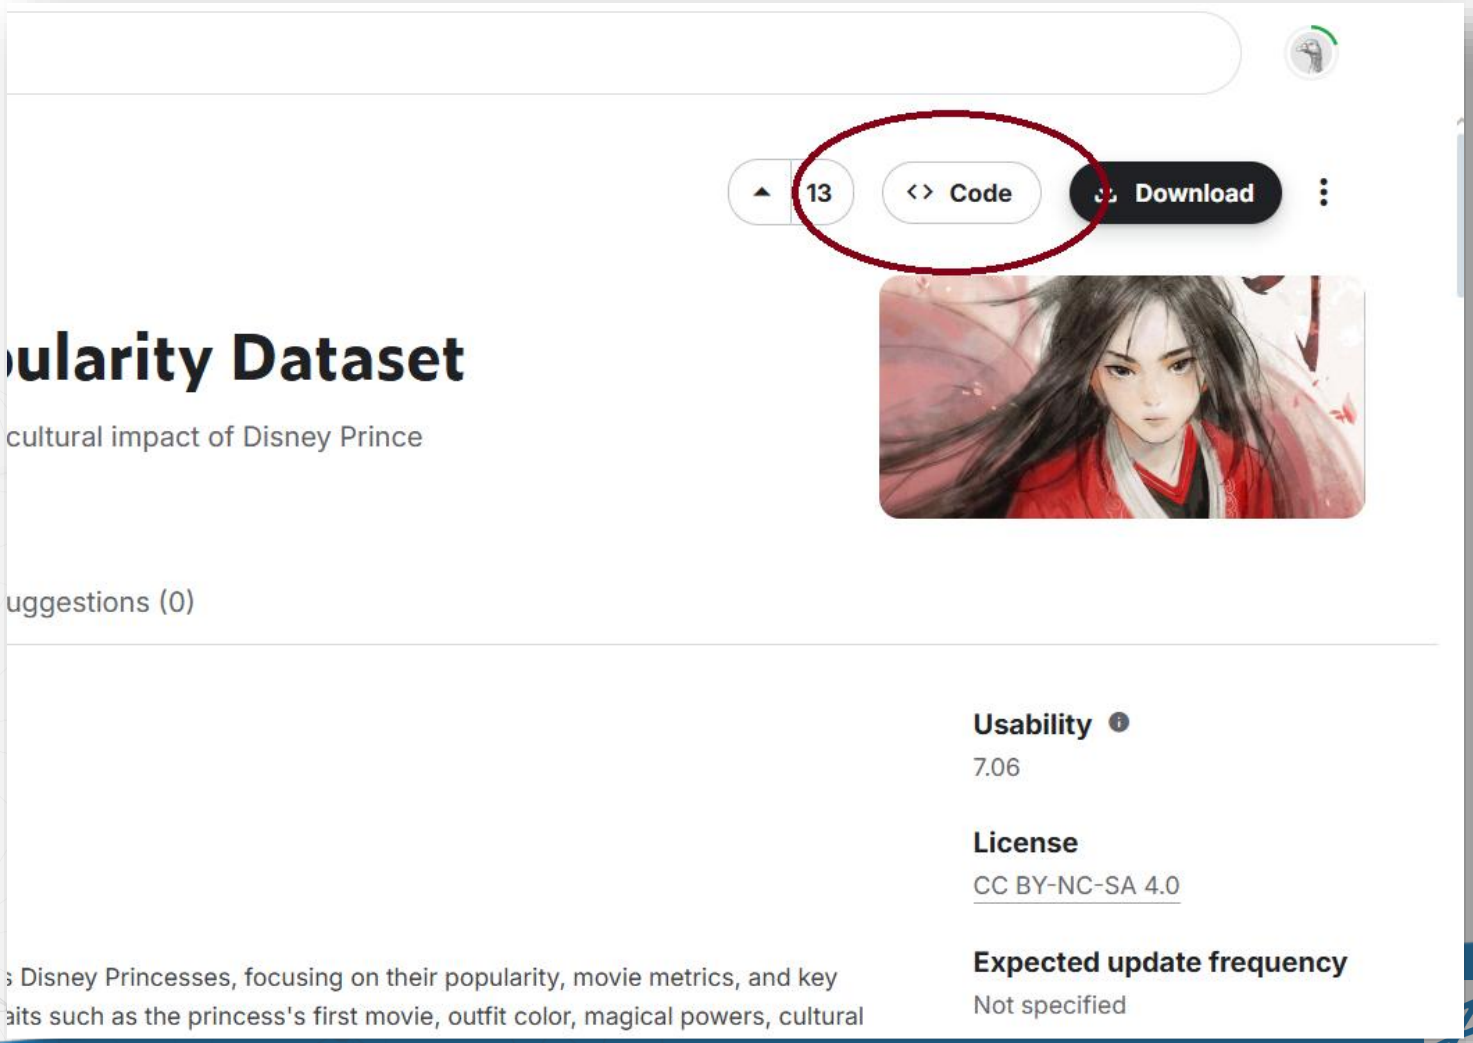

UNIFACISA
CENTRO UNIVERSITÁRIO

Como baixar datasets no Kaggle?

www.kaggle.com/datasets/hamnakaleemds/disney-princess-popularity-dataset/data

Search

HAMNA KALEEM · UPDATED 5 DAYS AGO

Disney Princess Popularity Dataset

A dataset analyzing the popularity, traits, and cultural impact of Disney Prince

Data Card | Code (4) | Discussion (0) | Suggestions (0)

About Dataset

Dataset Title: Disney Princess Popularity Dataset

Description:

This dataset provides an in-depth analysis of various Disney Princesses, focusing on their popularity, mo
characteristics. It includes detailed information on traits such as the princess's first movie, outfit color, m
origin, and more. The dataset is designed for machine learning enthusiasts and data scientists interested
attributes of Disney Princesses contribute to their iconic status and popularity over time.

The dataset includes both categorical and numerical features related to the princesses and their movies.
users can perform a wide range of classification, regression, and exploratory tasks to gain insights into w

es from Google to deliver and enhance the quality of its services and to analyze traffic.

LOAD VIA

kagglehub - pandas **DataFrame**

New to Kaggle API? Here's how to set up your API keys

```
# Install dependencies as needed:
# pip install kagglehub[pandas-datasets]
import kagglehub
from kagglehub import KaggleDatasetAdapter

# Set the path to the file you'd like to load
file_path = ""

# Load the latest version
df = kagglehub.load_dataset(
  KaggleDatasetAdapter.PANDAS,
  "hamnakaleemds/disney-princess-popularity-data
set",
  file_path,
  # Provide any additional arguments like
  # sql_query or pandas_kwargs. See the
  # documenation for more information:
  # https://github.com/Kaggle/kagglehub/blob/mai
n/README.md#kaggledatasetadapterpandas
)

print("First 5 records:", df.head())
```

Create a notebook

FACISA CENTRO UNIVERSITÁRIO

Como baixar datasets no Kaggle?

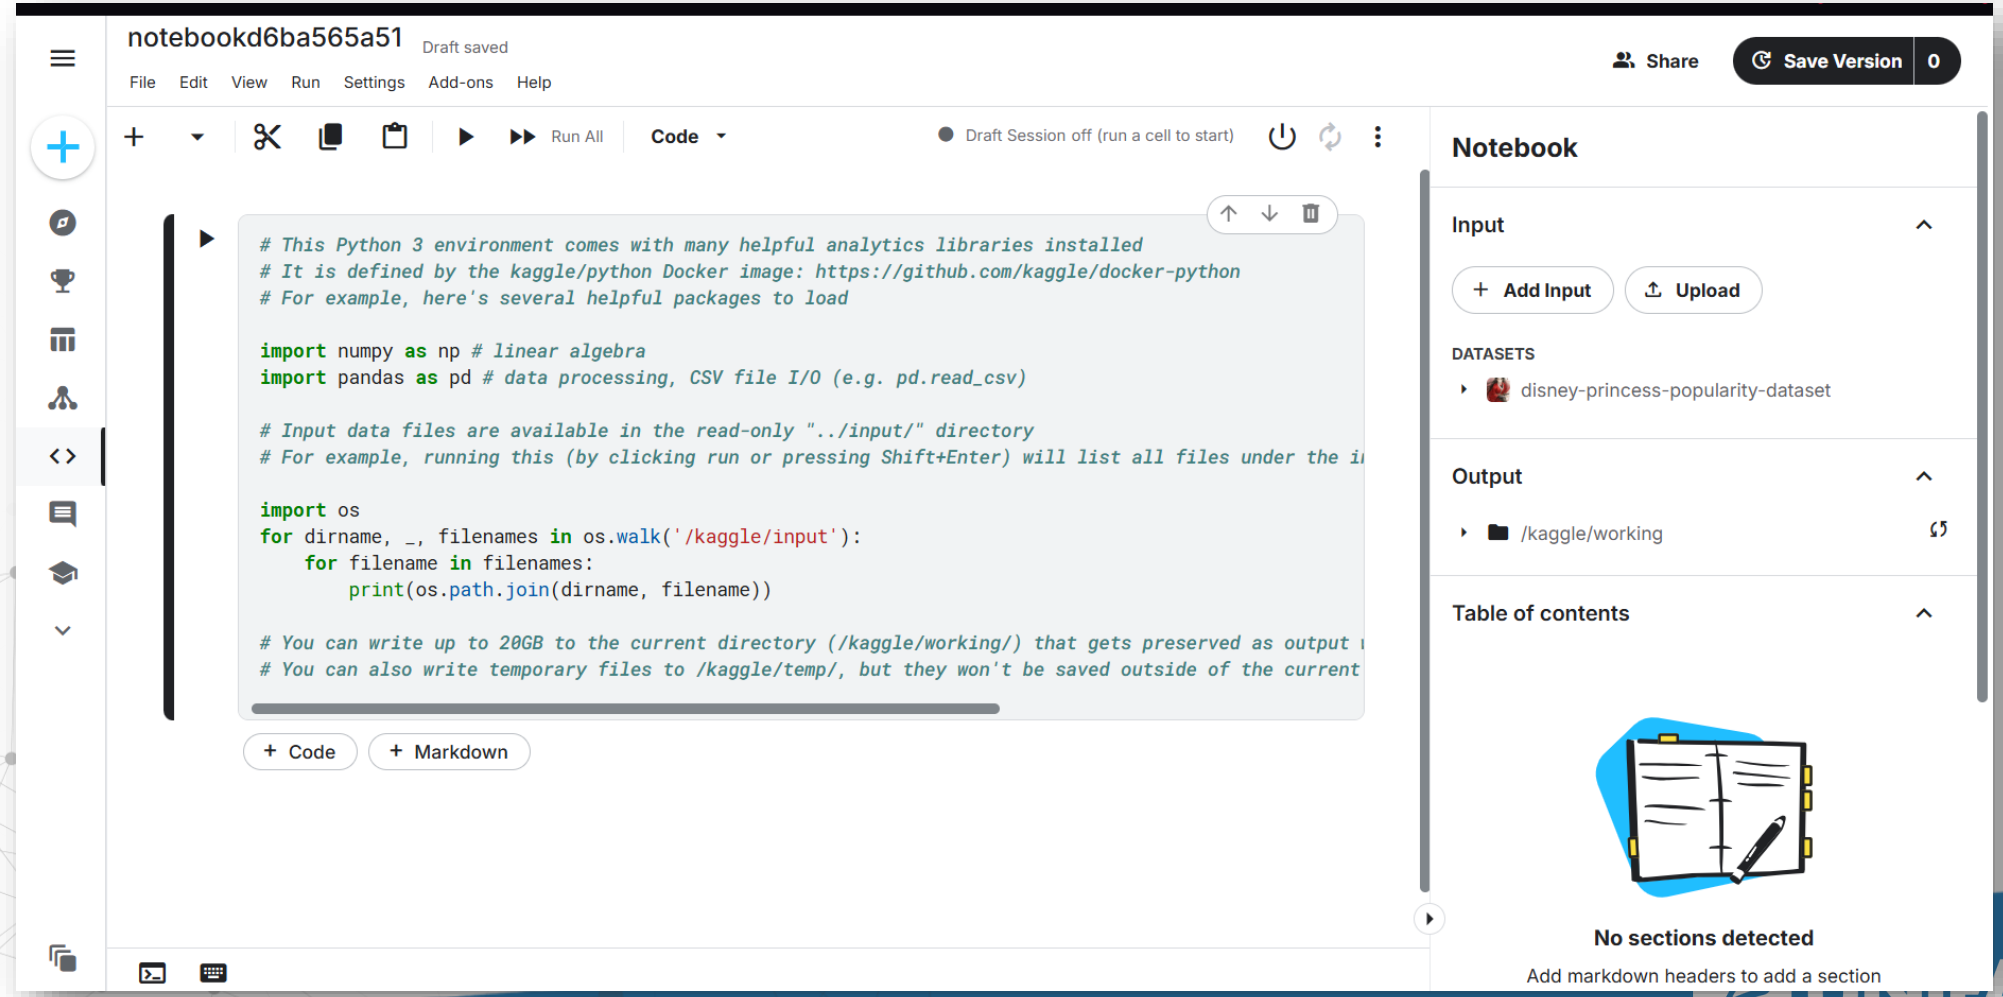

UNIFACISA
CENTRO UNIVERSITÁRIO

Como baixar datasets no Kaggle?

notebookd6ba565a51 Draft saved

File Edit View Run Settings Add-ons Help

Share | Save Version 0

Run All | Code | Draft Session (8m)

```python
# This Python 3 environment comes with many helpful analytics libraries installed
# It is defined by the kaggle/python Docker image: https://github.com/kaggle/docker-python
# For example, here's several helpful packages to load

import numpy as np # linear algebra
import pandas as pd # data processing, CSV file I/O (e.g. pd.read_csv)

# Input data files are available in the read-only "../input/" directory
# For example, running this (by clicking run or pressing Shift+Enter) will list all files under the i

import os
for dirname, _, filenames in os.walk('/kaggle/input'):
    for filename in filenames:
        print(os.path.join(dirname, filename))
```

```
/kaggle/input/disney-princess-popularity-dataset/disney_princess_popularity_dataset_300_rows.csv
```

+ Code + Markdown

Notebook

Input

+ Add Input | Upload

DATASETS

disney-princess-popularity-dataset

Output (72KiB / 19.5GiB)

/kaggle/working

Table of contents

No sections detected

Add markdown headers to add a section

UNIFACISA CENTRO UNIVERSITÁRIO

Como baixar datasets no Kaggle?

notebookd6ba565a51 Draft saved

File Edit View Run Settings Add-ons Help

Share | Save Version 0

Run All | Code | Draft Session (11m)

```python
# This Python 3 environment comes with many helpful analytics libraries installed
# It is defined by the kaggle/python Docker image: https://github.com/kaggle/docker-python
# For example, here's several helpful packages to load

import numpy as np # linear algebra
import pandas as pd # data processing, CSV file I/O (e.g. pd.read_csv)

# Input data files are available in the read-only "../input/" directory
# For example, running this (by clicking run or pressing Shift+Enter) will list all files under the input directo

import os
for dirname, _, filenames in os.walk('/kaggle/input'):
    for filename in filenames:
        print(os.path.join(dirname, filename))

df = pd.read_csv('/kaggle/input/disney-princess-popularity-dataset/disney_princess_popularity_dataset_300_rows.

df.head(1)
```

```
/kaggle/input/disney-princess-popularity-dataset/disney_princess_popularity_dataset_300_rows.csv
```

[14]:

	PrincessName	FirstMovieTitle	FirstMovieYear	MovieRuntimeMinutes	NumberOfSongs	HasSoloSong	HasDuet	HairColor	EyeColor	OutfitPr
0	Pocahontas	Pocahontas's Adventure	1977	85	4	No	Yes	Brown	Green	

1 rows × 36 columns

Notebook

Input

+ Add Input | Upload

DATASETS

disney-princess-popularity

Output (72KiB / 19.5GiB)

/kaggle/working

Table of contents

No sections detected

Add markdown headers to add a section

Principais ferramentas de análise de dados

- Linguagens de programação
  - Python
  - R
  - Java
- Softwares low-code ou no-code
  - Excel
  - Power BI (Microsoft)
  - Tableau
  - Looker (Google)

UNIFACISA
CENTRO UNIVERSITÁRIO

Principais bibliotecas

- Pandas: Manipulação de dados em tabelas (DataFrames)
- NumPY: Cálculos vetorizados e matrizes numéricas
- MatPlotLib / Searborn / Plotly: Gráficos e visualizações
- TensorFlow / PyTorch: modelagem de deep learning

Principais serviços em nuvem

- Google BigQuery: análise de grandes volumes de dados (BigData)
- AWS Athena: Consultas SQL em dados armazenados no S3
- Databricks: Plataforma de análise unificada (Spark + ML)
- Snowflake: Plataforma de soluções de banco de dados em nuvem

Stack para análise de dados

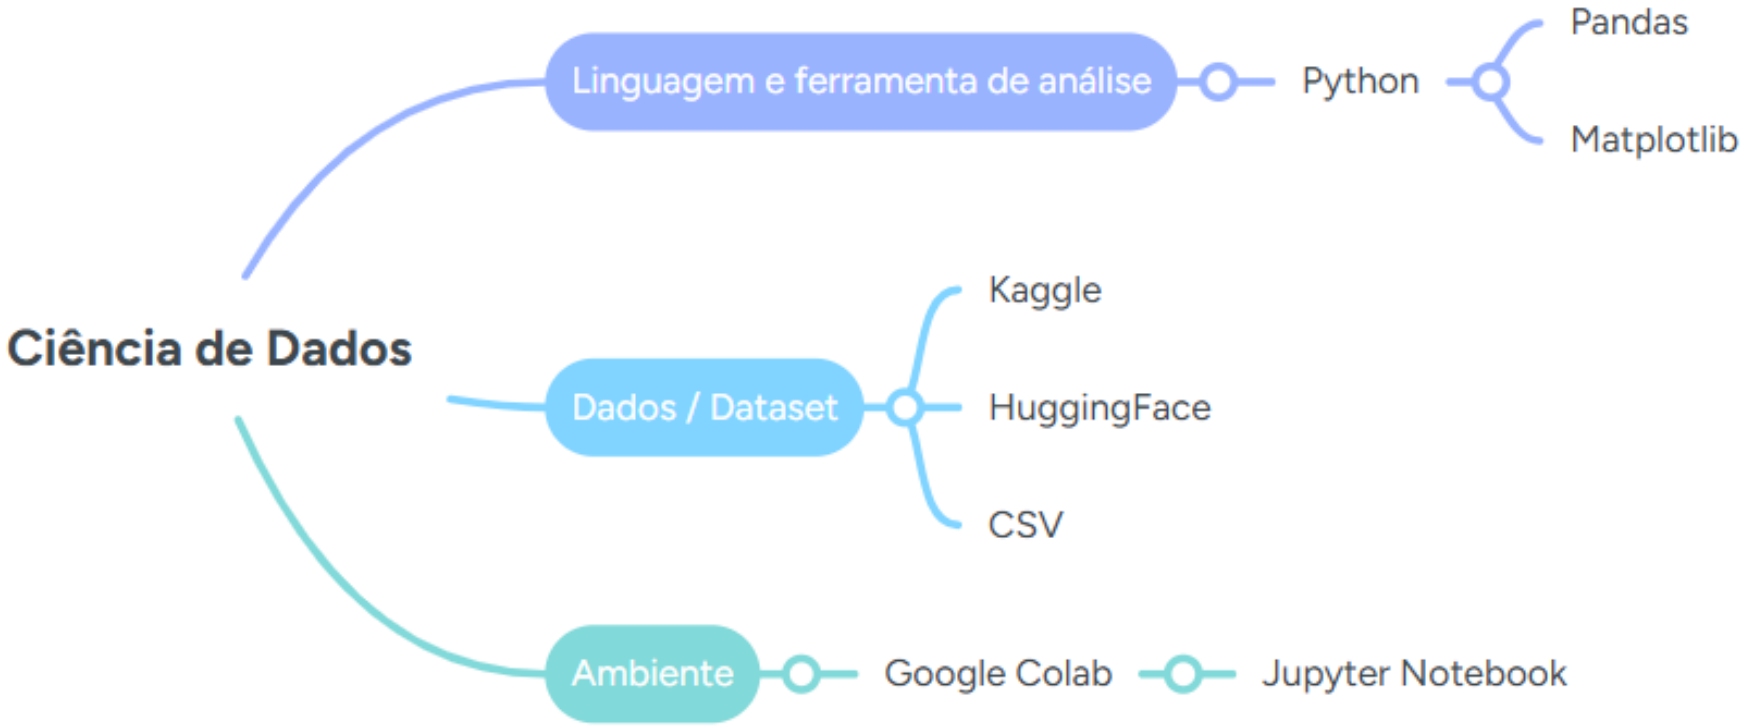

UNIFACISA
CENTRO UNIVERSITÁRIO

Stack para análise de dados + ML

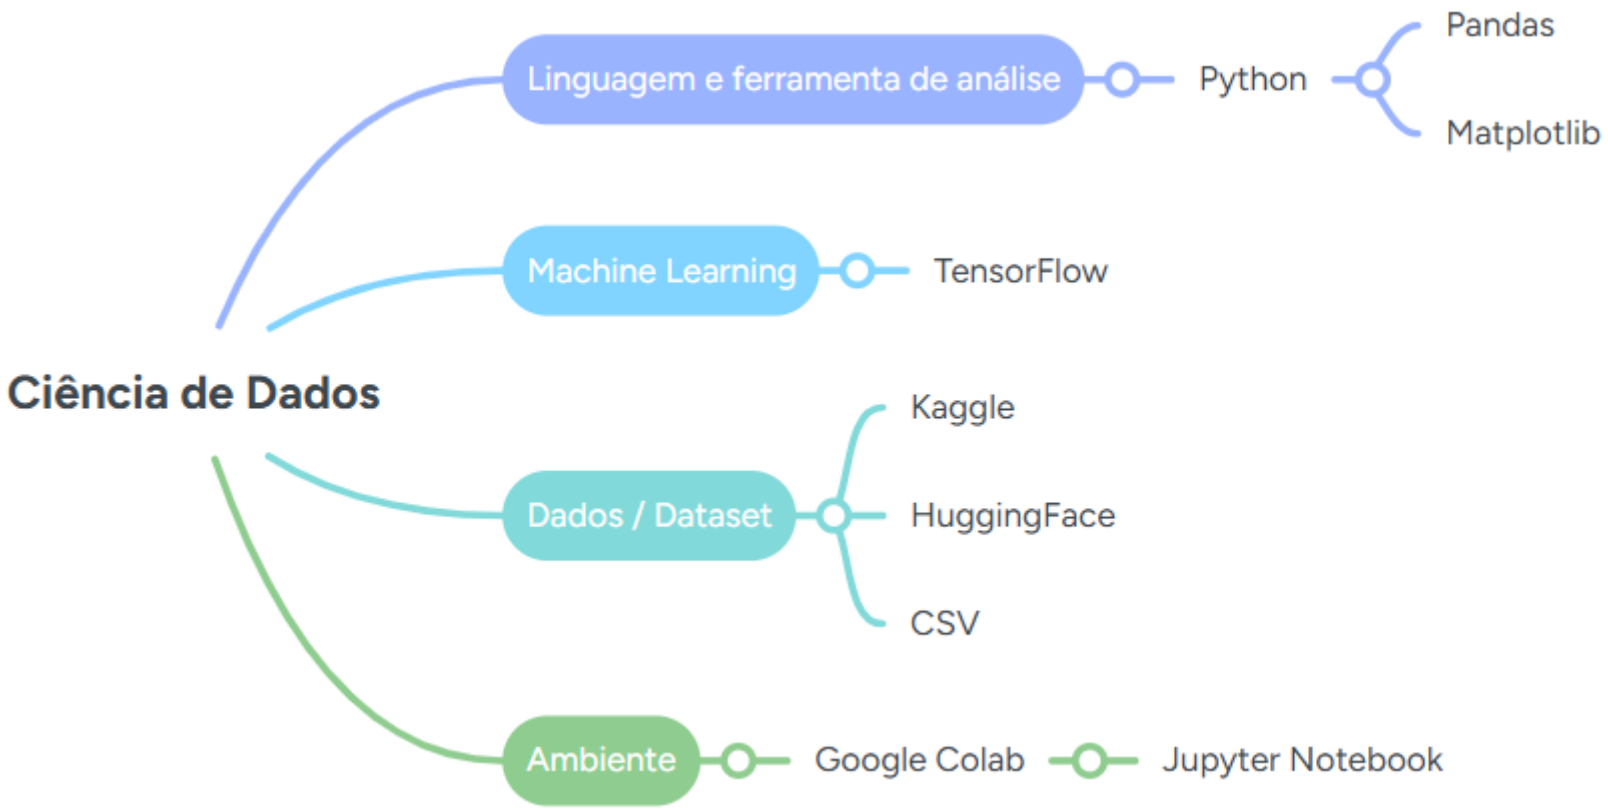

UNIFACISA
CENTRO UNIVERSITÁRIO

Stack para cientista de dados + BigData

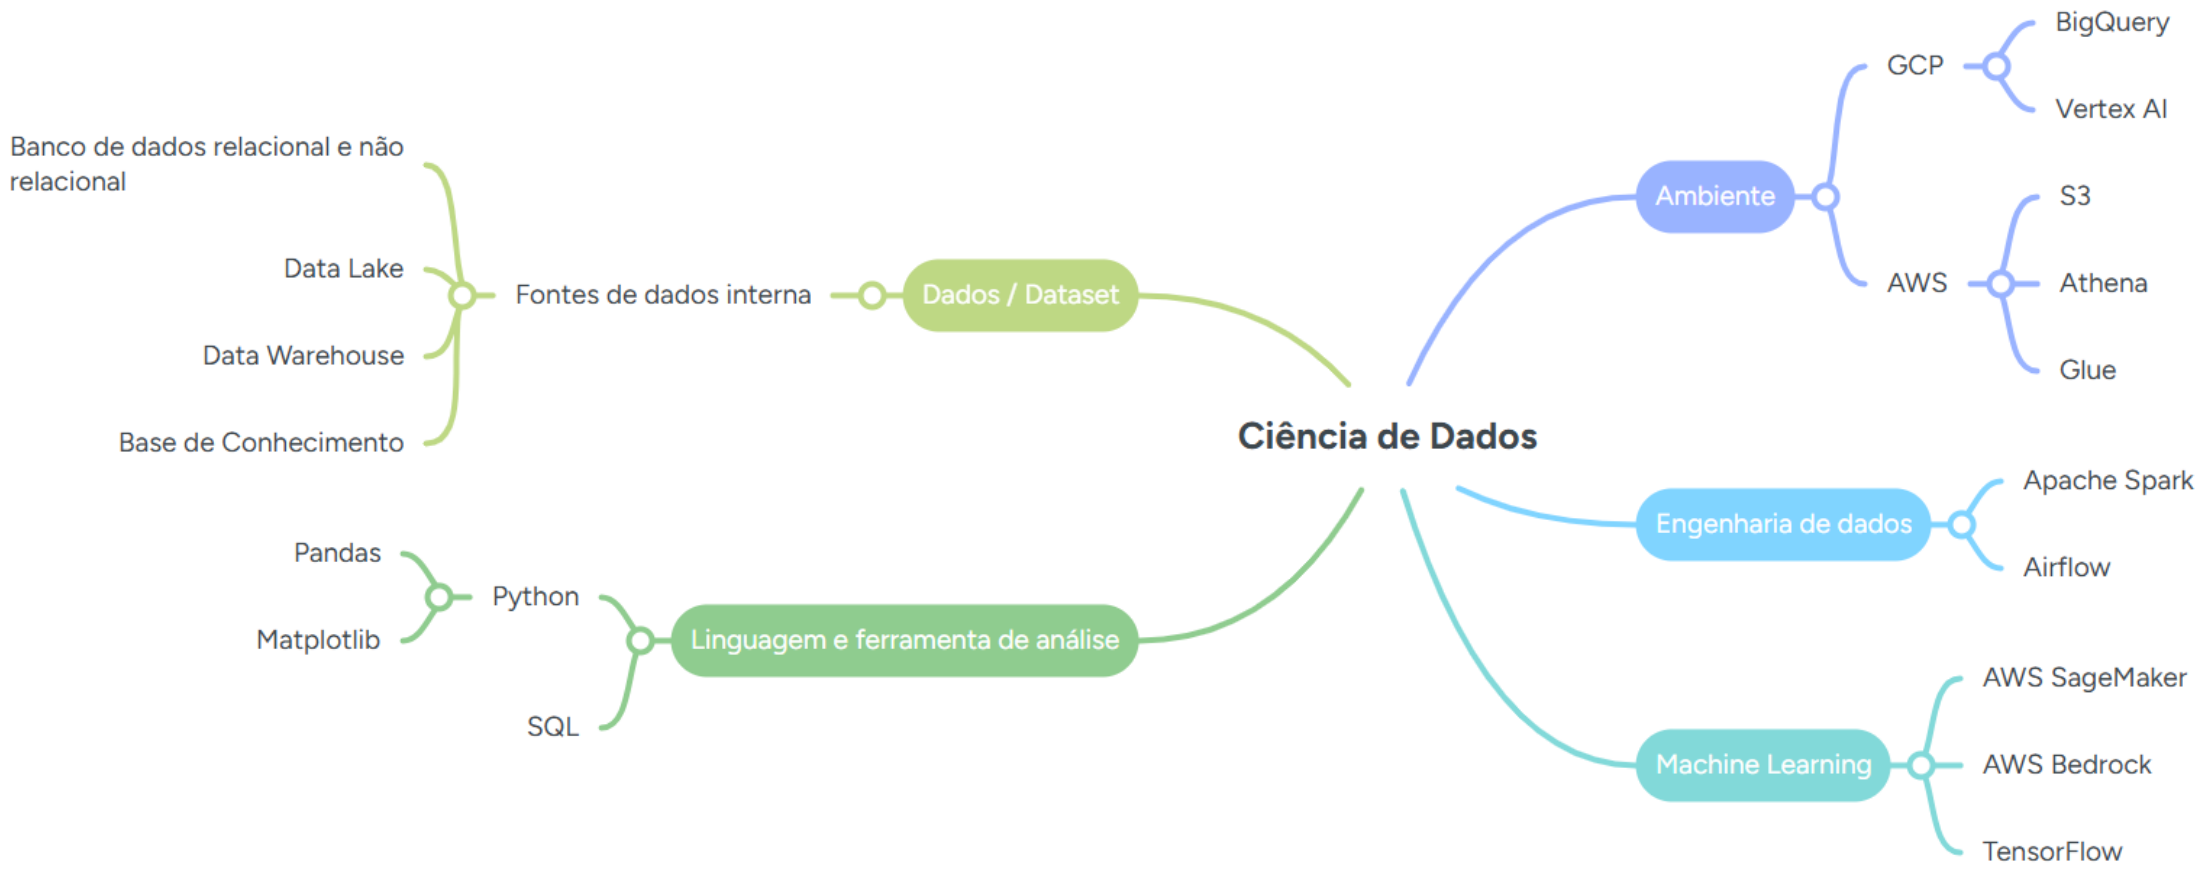

UNIFACISA
CENTRO UNIVERSITÁRIO

Configurando Google Colaboratory

- + Novo > Mais > Google Colaboratory

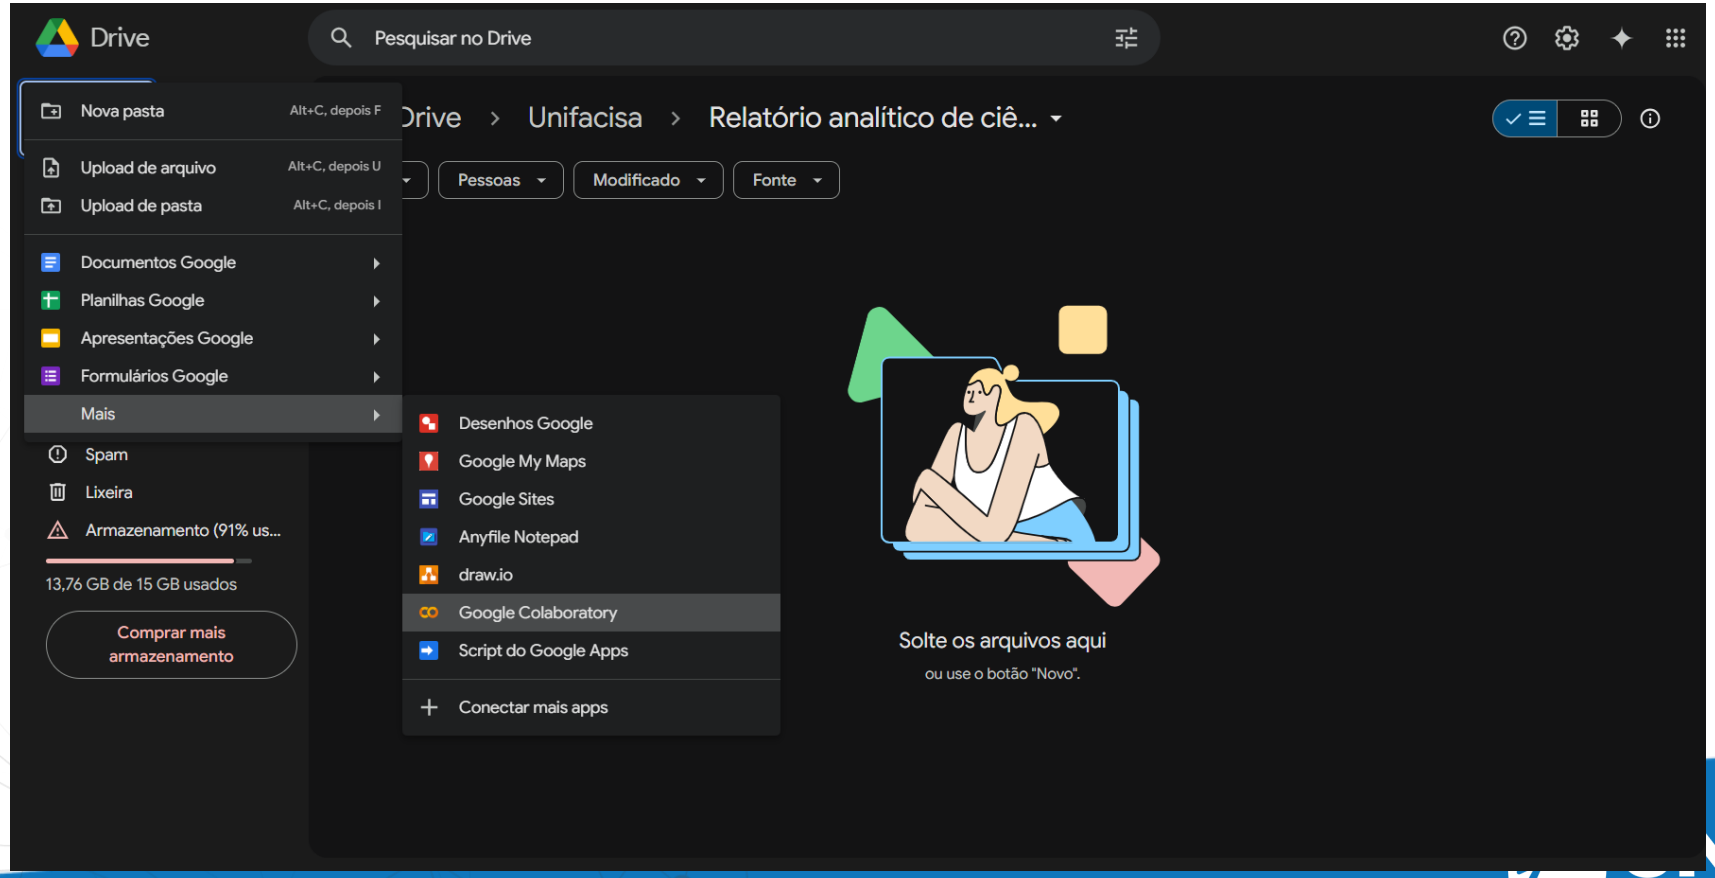

Configurando Google Colaboratory

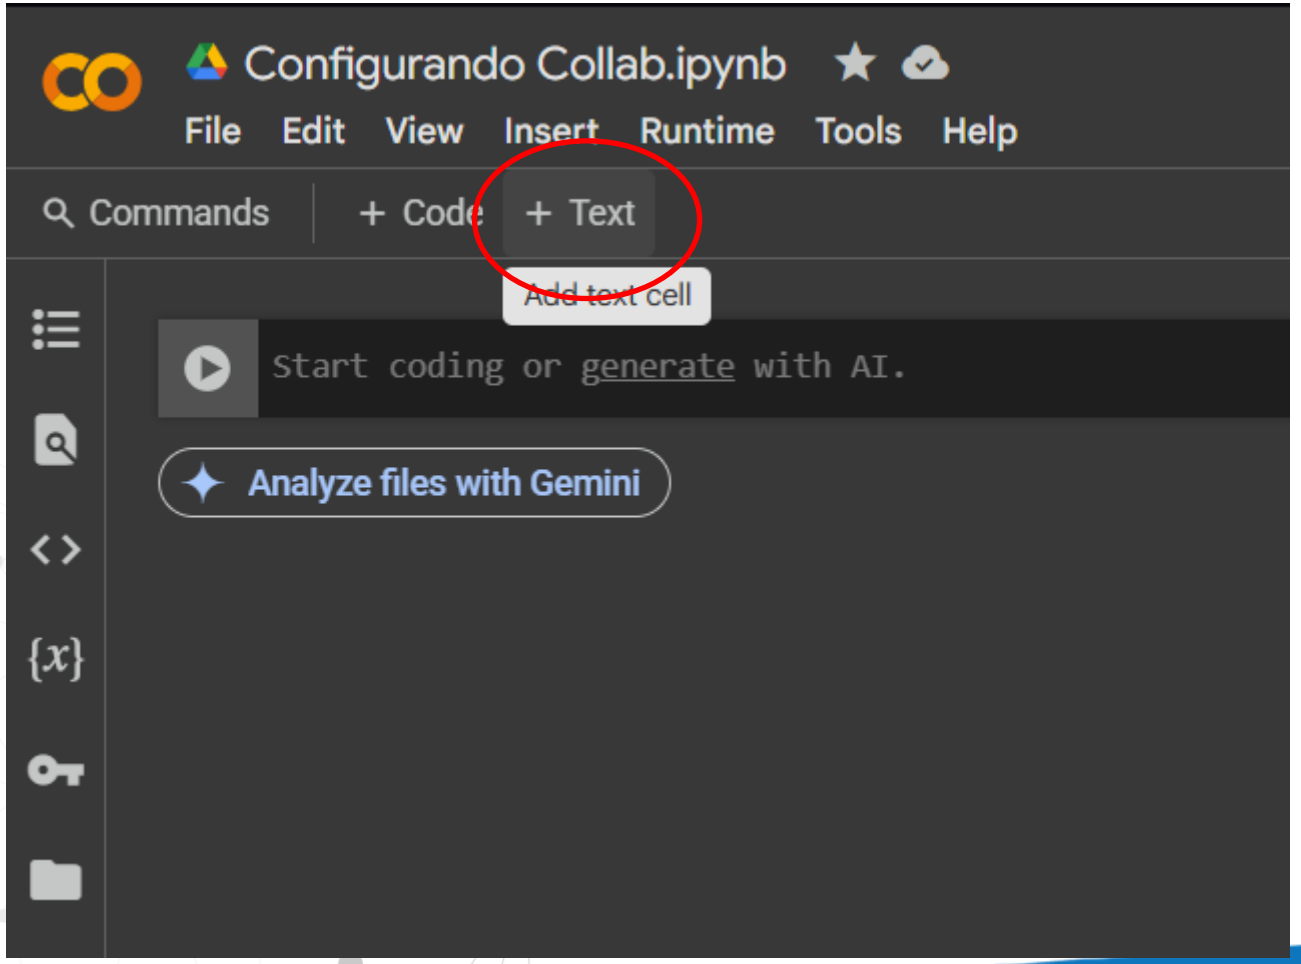

UNIFACISA
CENTRO UNIVERSITÁRIO

Configurando Google Colaboratory

UNIFACISA
CENTRO UNIVERSITÁRIO

Configurando Google Colaboratory

UNIFACISA
CENTRO UNIVERSITÁRIO

Configurando Google Colaboratory

- **Table of contents** é o sumário no Google Colaboratory, serve para organizar e navegar rapidamente dentro do notebook

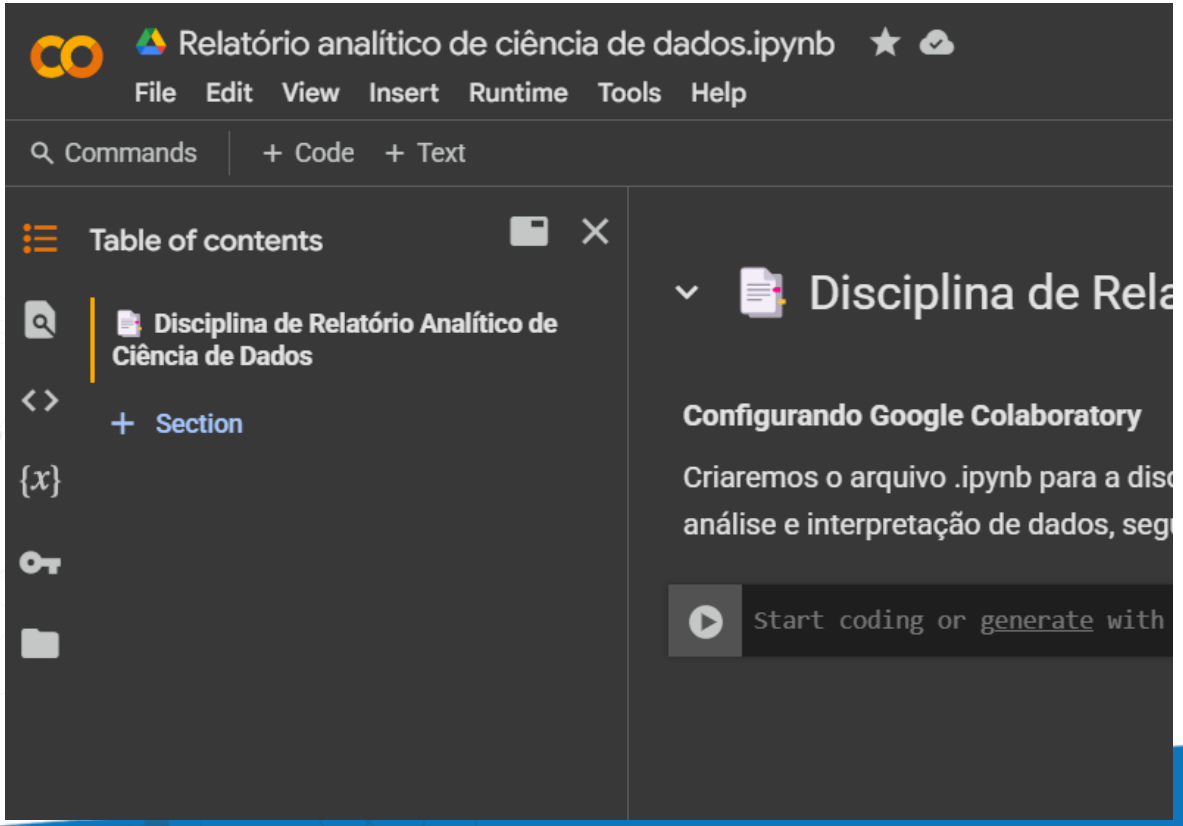

UNIFACISA
CENTRO UNIVERSITÁRIO

Configurando Google Colaboratory

- **Find and replace** no Google Colaboratory, serve para localizar rapidamente trechos de código ou palavras, e substituí-las

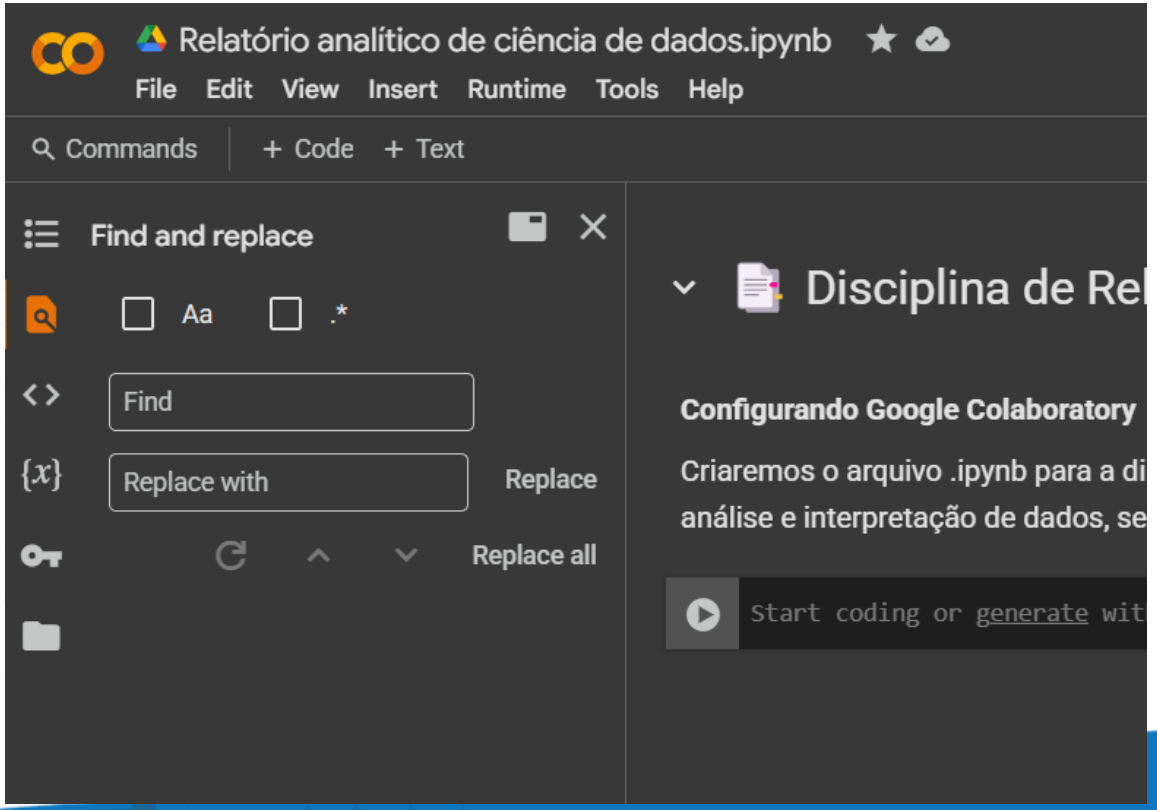

UNIFACISA
CENTRO UNIVERSITÁRIO

Configurando Google Colaboratory

- **Code snippets** no Google Colaboratory, serve para inserir trechos prontos de código, acelerar tarefas e aprender com exemplos, usem com parcimônia

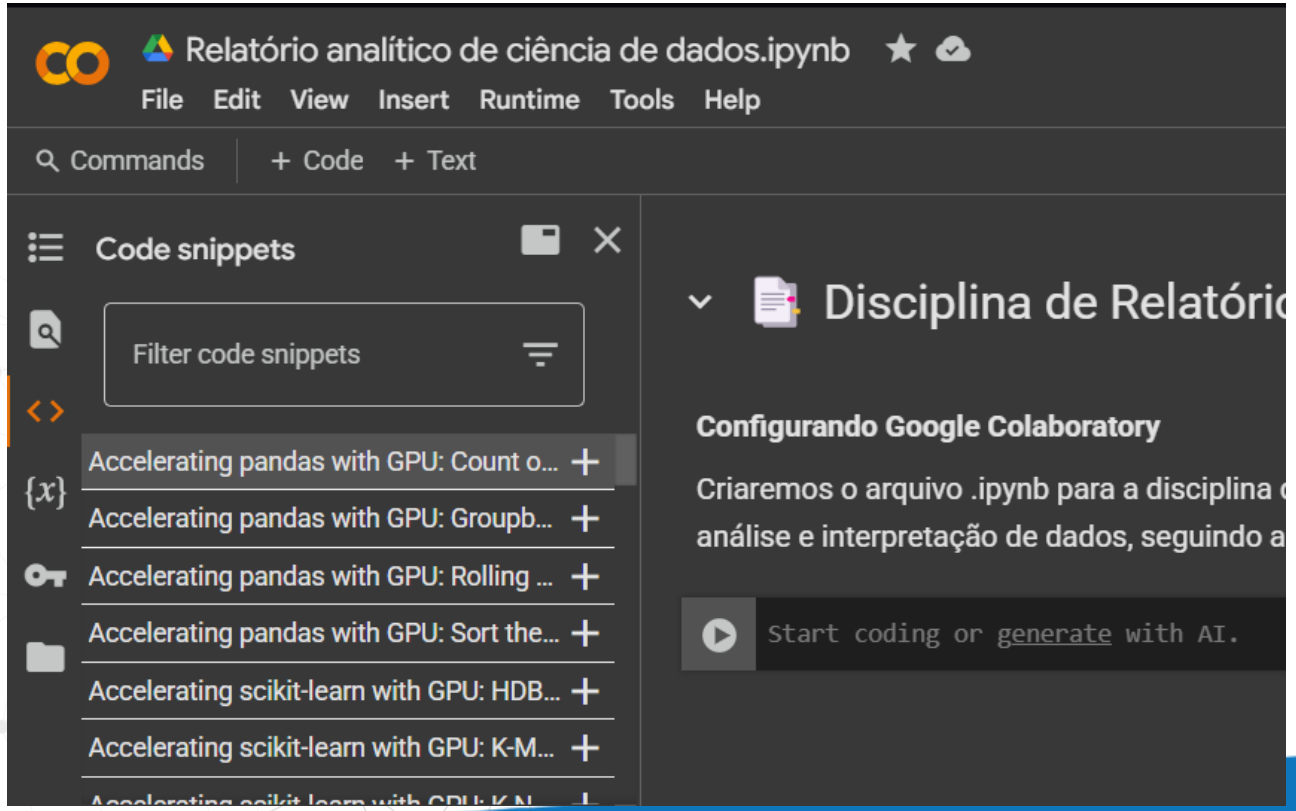

UNIFACISA
CENTRO UNIVERSITÁRIO

Configurando Google Colaboratory

- **Variables** no Google Colaboratory, serve para mostrar todas as variáveis criadas para o notebook em tempo real

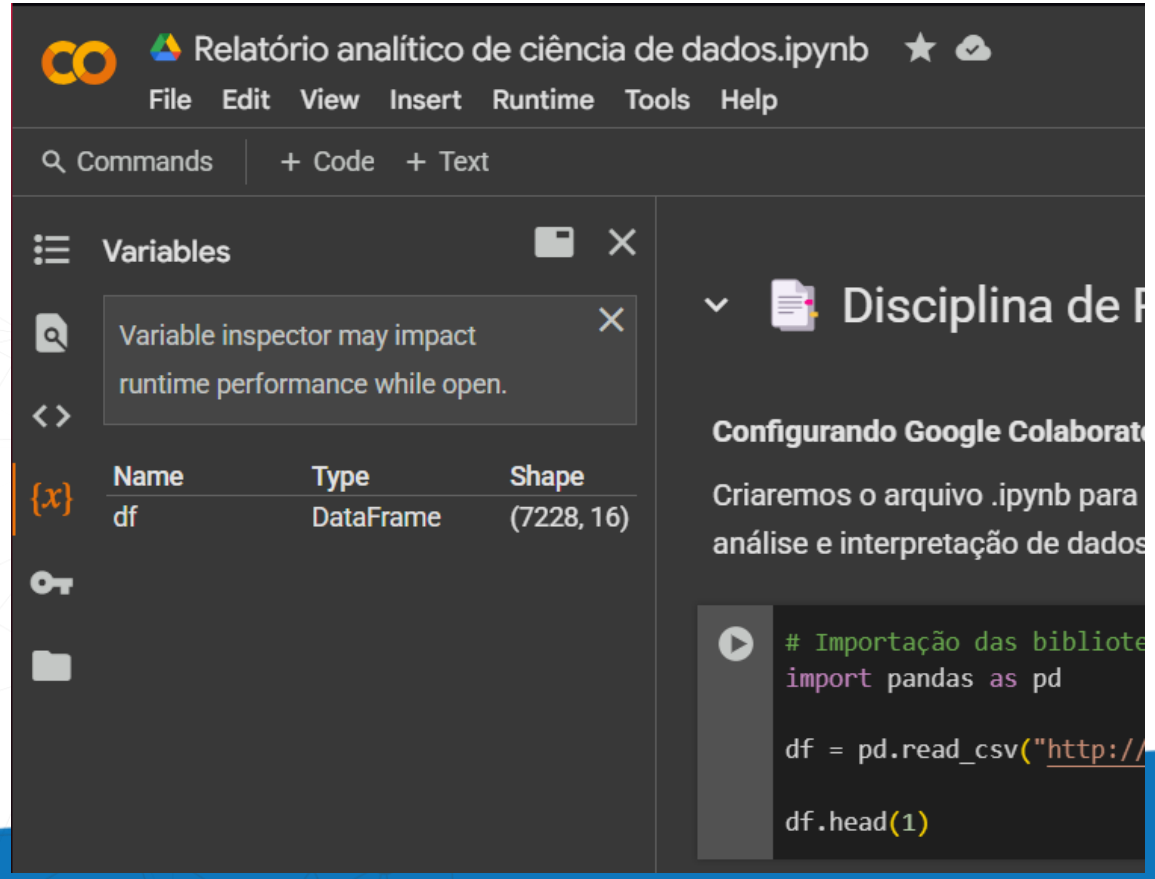

UNIFACISA
CENTRO UNIVERSITÁRIO

Configurando Google Colaboratory

- **Secrets** no Google Colaboratory, serve para armazenar e gerenciar dados sensíveis de forma segura, como chaves de API, credenciais de banco de dados, tokens de autenticação, entre outros, sem expor essas informações diretamente no código

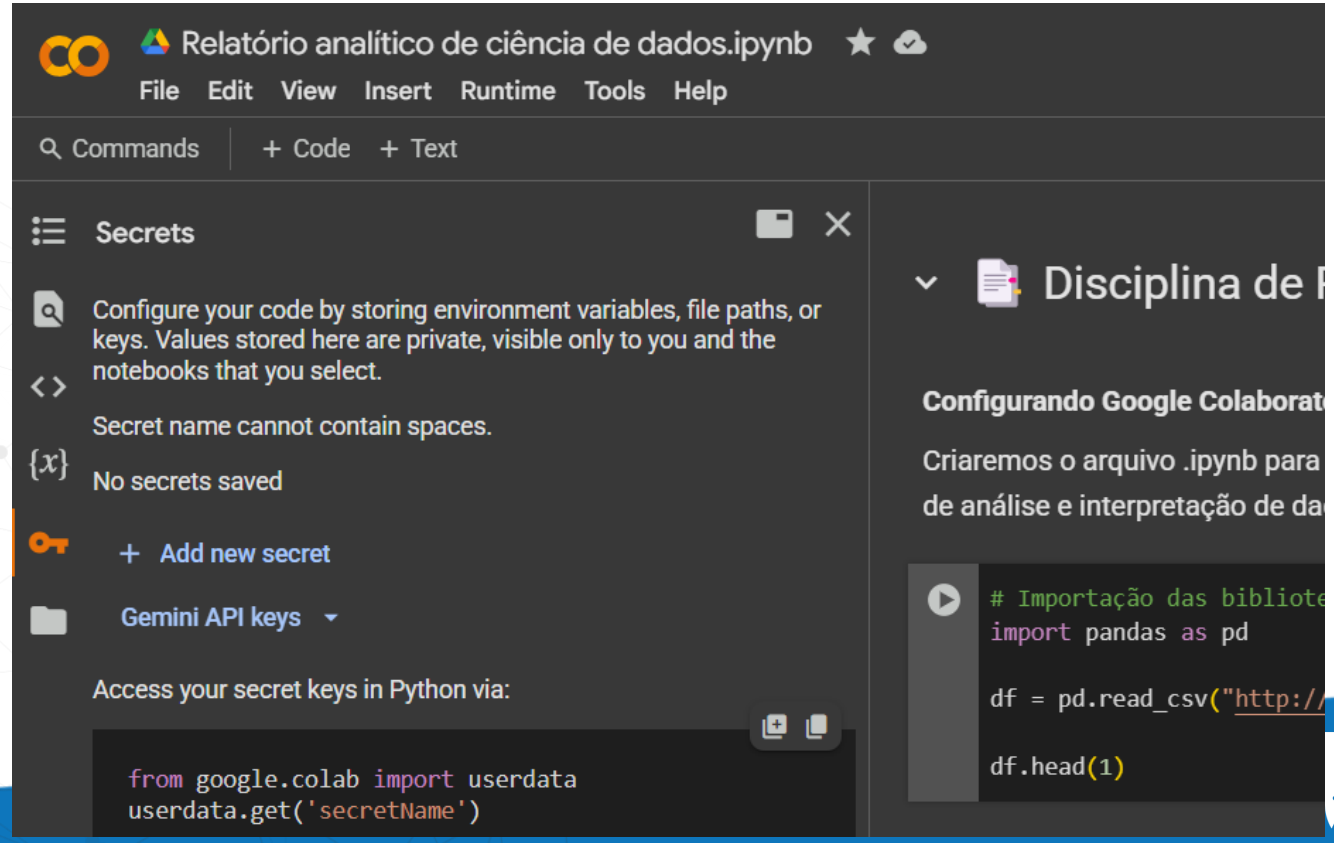

UNIFACISA
CENTRO UNIVERSITÁRIO

Configurando Google Colaboratory

- **Files** no Google Colaboratory, serve gerenciar os arquivos usados ou gerados dentro do notebook, como datasets, relatórios, etc

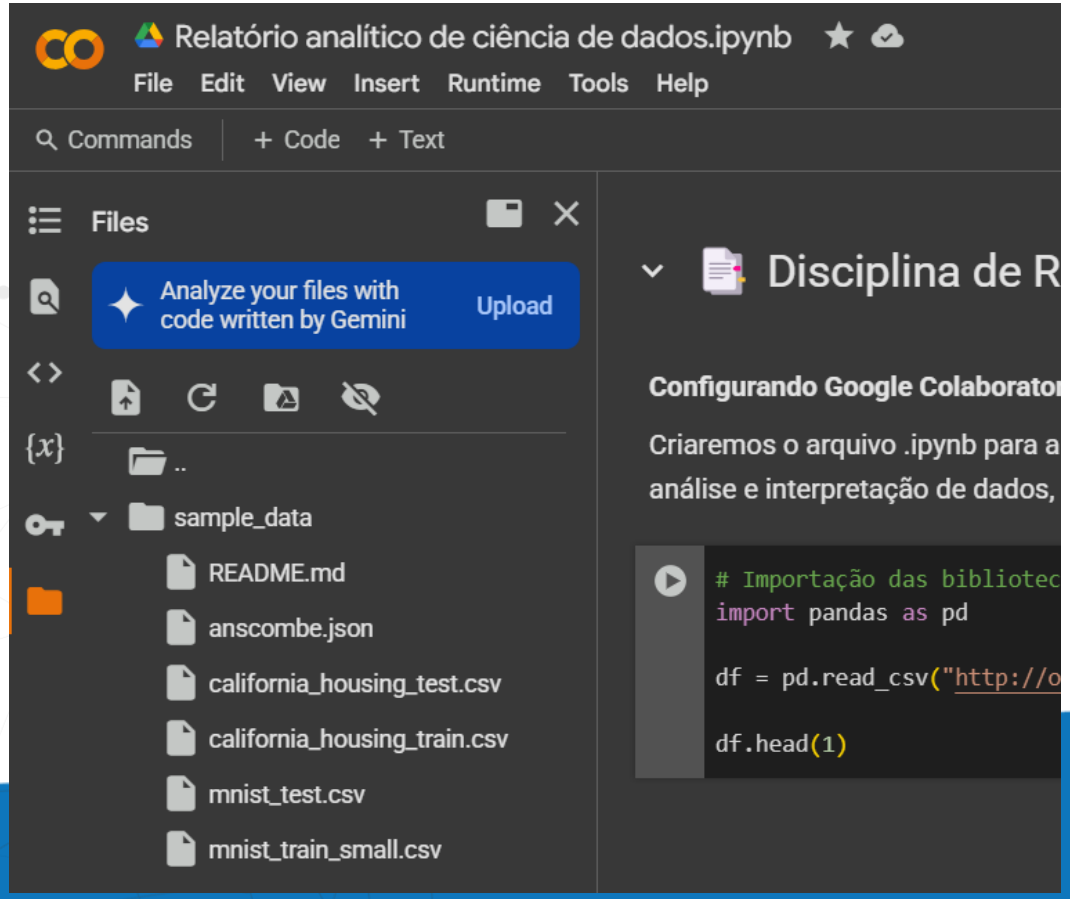

UNIFACISA
CENTRO UNIVERSITÁRIO

Importando as primeiras bibliotecas

```
# Importação das bibliotecas principais
import pandas as pd
import seaborn as sns
import numpy as np
```

UNIFACISA
CENTRO UNIVERSITÁRIO

Importando as primeiras bibliotecas

Relatório analítico de ciência de dados.ipynb

File Edit View Insert Runtime Tools Help

Commands + Code + Text

Disciplina de Relatório Analítico de Ciência de Dados

Configurando Google Colaboratory

Criaremos o arquivo .ipynb para a disciplina de Elaboração de relatório análitico de ciência de dados, com o intuito de aplicar técnicas de análise e interpretação de dados, seguindo as etapas de pré-processamento, exploração e análise.

0s

```
# Importação das bibliotecas principais
import pandas as pd

df = pd.read_csv("http://orionwinter.github.io/datasets/sao-paulo-rentals-april2019.csv")
```

UNIFACISA CENTRO UNIVERSITÁRIO

Importando as primeiras bibliotecas

análise e interpretação de dados, seguindo as etapas de pré-processamento, exploração e análise.

```
# Importação das bibliotecas principais
import pandas as pd

df = pd.read_csv("http://orionwinter.github.io/datasets/sao-paulo-rentals-april2019.csv"
```

```
  File "<ipython-input-5-479a3135eecf>", line 4
    df = pd.read_csv("http://orionwinter.github.io/datasets/sao-paulo-rentals-april2019.csv"
                                                                                            ^

SyntaxError: incomplete input
```

UNIFACISA
CENTRO UNIVERSITÁRIO

UNIFACISA
CENTRO UNIVERSITÁRIO

www.unifacisa.edu.br
(83) 2101.8877
Av. Senador Argemiro de Figueiredo, 1901 - Itararé
CEP: 58411-020 - Campina Grande/PB

É proibido fotografar, gravar, registrar, compartilhar ou divulgar, por qualquer outro meio, a imagem, a voz ou conteúdo autoral (slides, apostilas, etc.) do professor, para utilização por ele não autorizada ou uso indevido, sob pena das responsabilidades civis, criminais e daquelas previstas nas normas internas da UNIFACISA.

UNIFACISA
CENTRO UNIVERSITÁRIO

UNIFACISA
CENTRO UNIVERSITÁRIO